

Курсовая работа

Классическое машинное обучение

Прогнозирование эффективности химических соединений для разработки лекарственных препаратов

Аналитический отчёт по EDA, регрессии и классификации

Дата подготовки: 11 июня 2026

1. Краткое резюме

В работе решалась задача оценки биологических свойств химических соединений по числовым молекулярным дескрипторам. Модели строились для трёх регрессионных таргетов: IC50, CC50 и SI. Также были решены четыре классификационные задачи: IC50 выше медианы, CC50 выше медианы, SI выше медианы и SI выше 8.

Главный результат оказался достаточно понятным. Для IC50 и CC50 в данных есть устойчивый сигнал, и модели на основе деревьев заметно превосходят baseline и линейные модели. Для SI ситуация сложнее: этот показатель является отношением CC50 к IC50, поэтому он намного сильнее реагирует на выбросы и ошибки в отдельных компонентах.

После очистки осталось 966 объектов и 187 признаков. Лучшие тестовые результаты регрессии в текущей версии: IC50 MAE 213.2, R^2 0.379; CC50 MAE 297.5, R^2 0.551; SI MAE 31.6, R^2 0.027.

2. Постановка задачи

Каждая строка датасета соответствует одному химическому соединению. Первые три ключевые величины: IC50, CC50 и SI. IC50 интерпретируется как показатель эффективности: чем меньше значение, тем активнее соединение. CC50 описывает токсичность: чем выше значение, тем менее токсично соединение для клеток. SI показывает селективность и рассчитывается как CC50 / IC50.

Для регрессии модели предсказывали численное значение каждого таргета. Для классификации целевая переменная превращалась в бинарную: показатель выше порога или нет. Для медианных задач порог считался только на train-части. Это важно, потому что иначе в разметку попала бы информация из test.

3. Подготовка данных

Сначала данные были проверены на пропуски, дубликаты и константные признаки. Пропусков было мало, поэтому строки с пропусками удалялись. Также были удалены константные признаки и полные дубли признаков. Такие признаки не дают новой информации модели и только увеличивают размерность.

Таблица 1. Итоги очистки данных

Показатель	Значение
Исходный размер	1001 строк, 213 колонок
Строки с пропусками	3
Удалено после dropna + duplicates	35
Размер после очистки	966 строк, 213 колонок
Константные признаки	18
Удалено дублирующих признаков	5
Итоговое число признаков	187
Проверка SI = CC50 / IC50	$\max diff = 1.82e-12$

4. Исследовательский анализ данных

EDA показал, что все три таргета имеют выраженную асимметрию. На исходной шкале большая часть наблюдений сжата около малых значений, а отдельные соединения формируют длинный правый хвост. Особенно сильно это заметно для SI.

Распределения целевых переменных на исходной шкале




Рисунок 1. Распределения IC50, CC50 и SI на исходной шкале

После $\log_{1p}$ распределения становятся более компактными. Это не решает задачу полностью, но помогает моделям для SI: ошибка MAE заметно снижается, хотя R^2 остаётся слабым.

Распределения целевых переменных после $\log_{1p}$




Рисунок 2. Распределения таргетов после $\log_{1p}$ -преобразования

Таблица 2. Описательная статистика целевых переменных

target	mean	std	min	median	q75	max
IC50, mM	218.978	395.412	0.004	45.223	225.227	4128.5
CC50, mM	583.888	632.692	0.701	422.159	886.389	4539.0
SI	74.118	696.637	0.011	3.913	16.332	15620.6

Проверка формулы подтвердила, что SI практически полностью совпадает с CC50 / IC50. Максимальное абсолютное расхождение составило $1.82e-12$. Это важный методологический момент: при прогнозировании SI нельзя использовать IC50 и CC50 как признаки.




Рисунок 3. Spearman-корреляция между целевыми переменными

Корреляции отдельных групп признаков с таргетами в основном слабые или умеренные. Максимальные значения находятся около 0.3. Это говорит о том, что задача не сводится к одному очевидному дескриптору. Модели должны использовать комбинации признаков.




Рисунок 4. Максимальная связь групп дескрипторов с таргетами

Таблица 3. Корреляции по группам признаков

target	group	n_features	max_abs_corr	mean_top5_abs_cor r	n_abs_corr_gt_02
CC50, mM	abstract_structure	29.000	0.304	0.292	19.000
CC50, mM	surface	57.000	0.277	0.219	2.000
CC50, mM	count_like	84.000	0.277	0.237	5.000
CC50, mM	weight	3.000	0.270	0.265	3.000
CC50, mM	bcut2d	8.000	0.156	0.128	0.000
CC50, mM	partial_charge	4.000	0.139	0.072	0.000
CC50, mM	qed_fraction	2.000	0.129	0.110	0.000
IC50, mM	count_like	84.000	0.292	0.249	5.000
IC50, mM	surface	57.000	0.270	0.243	7.000
IC50, mM	bcut2d	8.000	0.222	0.145	1.000
IC50, mM	abstract_structure	29.000	0.180	0.170	0.000
IC50, mM	qed_fraction	2.000	0.130	0.096	0.000

В данных также есть сильная мультиколлинеарность. Например, MolWt и ExactMolWt практически совпадают по ранговой корреляции. Для линейных моделей это может ухудшать устойчивость коэффициентов. Для RandomForest и ExtraTrees это менее критично, поэтому деревья были основным направлением моделирования.

Таблица 4. Примеры сильно коррелирующих признаков

feature_1	feature_2	abs_spearman_corr
MolWt	ExactMolWt	1.000
Chi1	HeavyAtomCount	0.998
MolWt	HeavyAtomMolWt	0.996
HeavyAtomMolWt	ExactMolWt	0.996
Chi1	lpc	0.994
Chi0	HeavyAtomCount	0.994
NumValenceElectrons	Chi0	0.991
LabuteASA	HeavyAtomCount	0.990

5. Регрессионные модели

Для регрессии сравнивались baseline, линейные модели с регуляризацией и ансамбли деревьев. Baseline нужен как нижняя точка сравнения: модель должна быть лучше простого предсказания медианы.

Первый важный вывод: IC50 и CC50 предсказываются заметно лучше, чем SI. Это согласуется с EDA: SI имеет самый тяжёлый хвост и является производной величиной.

Таблица 5. Сравнение регрессионных моделей на test

target	model	transform	MAE	RMSE	R2
CC50, mM	ExtraTrees	raw	297.541	448.005	0.551
CC50, mM	RandomForest	raw	310.143	460.524	0.526
CC50, mM	ElasticNet	raw	358.553	505.521	0.429
CC50, mM	Ridge	raw	365.329	517.178	0.402
CC50, mM	Dummy median	raw	489.087	684.914	-0.048
IC50, mM	ExtraTrees	raw	213.171	372.924	0.379
IC50, mM	Dummy median	raw	225.444	511.287	-0.168
IC50, mM	RandomForest	raw	226.892	388.431	0.326
IC50, mM	ElasticNet	raw	237.734	377.354	0.364
IC50, mM	Ridge	raw	240.885	383.223	0.344
SI	ExtraTrees	log1p	31.592	145.390	0.027
SI	RandomForest	log1p	31.856	146.335	0.014
SI	ElasticNet	log1p	32.202	145.212	0.029
SI	Ridge	log1p	32.343	141.188	0.082
SI	Dummy median	raw	33.416	150.528	-0.043
SI	ExtraTrees	raw	97.261	402.939	-6.477
SI	RandomForest	raw	103.009	386.818	-5.890
SI	ElasticNet	raw	144.160	374.180	-5.447
SI	Ridge	raw	154.171	392.170	-6.082

В качестве финальных регрессионных решений были выбраны модели с лучшим качеством на валидации. Для IC50 и CC50 лучше всего сработал ExtraTrees на исходной шкале. Для SI лучшим по MAE оказался ExtraTrees с log1p-преобразованием таргета.

Таблица 6. Финальные регрессионные модели

target	model	transform	MAE	RMSE	R2
CC50, mM	ExtraTrees	raw	297.541	448.005	0.551
IC50, mM	ExtraTrees	raw	213.171	372.924	0.379
SI	ExtraTrees	log1p	31.592	145.390	0.027




Рисунок 5. R^2 финальных регрессионных моделей на test



Рисунок 6. MAE финальных регрессионных моделей на test

Отдельно проверялась идея предсказывать SI не напрямую, а через прогнозы IC50 и CC50. Логика понятная: если IC50 и CC50 предсказываются лучше, можно рассчитать SI как $CC50_pred / IC50_pred$. На практике этот вариант не дал стабильного выигрыша. Ошибки двух моделей накапливаются, а деление на IC50 делает итог чувствительным к ошибкам в знаменателе.

Таблица 7. Прямой прогноз SI и расчёт через IC50/CC50

Также проверялись более сложные улучшения: ratio-признаки, top-N отбор по важности и простые ансамбли из двух моделей. Эти эксперименты помогли понять границу полезности усложнения. Для IC50 и CC50 простой ансамбль деревьев уже забирает основную часть сигнала. Дополнительные признаки не дали устойчивого прироста, поэтому финальное решение не перегружалось лишней архитектурой.

6. Классификационные модели

После регрессии были решены четыре задачи классификации. Здесь модель не должна предсказать точное значение показателя. Ей нужно определить, выше соединение заданного порога или ниже. Поэтому классификация по SI может быть проще, чем регрессия SI.

Таблица 8. Баланс классов на train

task	threshold	positive_class_%	n
IC50>med	45.223	50.000	676.000
CC50>med	436.563	50.000	676.000
SI>med	4.298	50.000	676.000
SI>8	8.000	35.503	676.000




Рисунок 7. Доля положительного класса в классификационных задачах

Для классификации сравнивались DummyClassifier, LogisticRegression, RandomForest и ExtraTrees. Медианные задачи сбалансированы примерно 50 на 50. Задача SI > 8 сложнее: положительный класс занимает около 35.5% train-выборки.

Таблица 9. Сравнение классификационных моделей на test

task	model	Accuracy	Precision	Recall	F1	ROC_AUC
CC50>med	RandomForest	0.766	0.753	0.775	0.764	0.858
CC50>med	ExtraTrees	0.745	0.730	0.761	0.745	0.846
CC50>med	LogisticRegression	0.703	0.689	0.718	0.703	0.785
CC50>med	Dummy frequent	0.510	0.000	0.000	0.000	0.500
IC50>med	RandomForest	0.731	0.730	0.676	0.702	0.814
IC50>med	ExtraTrees	0.724	0.726	0.662	0.692	0.815
IC50>med	LogisticRegression	0.676	0.657	0.647	0.652	0.762
IC50>med	Dummy frequent	0.531	0.000	0.000	0.000	0.500
SI>8	ExtraTrees	0.717	0.596	0.560	0.577	0.731
SI>8	RandomForest	0.717	0.605	0.520	0.559	0.725
SI>8	LogisticRegression	0.676	0.528	0.560	0.544	0.669
SI>8	Dummy frequent	0.655	0.000	0.000	0.000	0.500

SI>med	RandomForest	0.683	0.613	0.730	0.667	0.722
SI>med	ExtraTrees	0.676	0.603	0.746	0.667	0.725
SI>med	LogisticRegression	0.648	0.577	0.714	0.638	0.684
SI>med	Dummy frequent	0.566	0.000	0.000	0.000	0.500

Таблица 10. Лучшие классификационные модели по F1 на test

task	model	Accuracy	Precision	Recall	F1	ROC_AUC
CC50>med	RandomForest	0.766	0.753	0.775	0.764	0.858
IC50>med	RandomForest	0.731	0.730	0.676	0.702	0.814
SI>8	ExtraTrees	0.717	0.596	0.560	0.577	0.731
SI>med	RandomForest	0.683	0.613	0.730	0.667	0.722




Рисунок 8. F1-score классификационных моделей на test

Лучше всего модели справились с задачами IC50 > median и CC50 > median. Для CC50 RandomForest получил F1 около 0.76 и ROC-AUC около 0.86. Для SI качество ниже, но всё равно заметно лучше baseline. Для SI > 8 задача сложнее из-за дисбаланса классов.

Confusion matrix для лучших классификаторов

Ниже приведены матрицы ошибок для моделей, которые показали лучший F1 на test в каждой классификационной задаче. Они показывают, где модель чаще ошибается: пропускает положительный класс или, наоборот, слишком часто относит соединения к положительному классу.




Рисунок. Confusion matrix для задачи IC50 > median(train)




Рисунок. Confusion matrix для задачи CC50 > median(train)




Рисунок. Confusion matrix для задачи SI > median(train)




Рисунок. Confusion matrix для задачи SI > 8

7. Обсуждение результатов

Регрессионная часть показала, что молекулярные дескрипторы реально содержат сигнал для IC50 и CC50. Для IC50 итоговый R^2 около 0.38, для CC50 около 0.55. Это не идеальное качество, но для небольшого датасета с химическими дескрипторами результат выглядит рабочим.

Для SI ситуация другая. На исходной шкале модель плохо объясняет дисперсию, потому что SI имеет сильные выбросы. Логарифмирование снижает MAE до примерно 31.6, но R^2 остаётся около 0.03. Это означает, что модель лучше ведёт себя на типичных значениях, но плохо ловит экстремальные SI.

Классификация показала более устойчивую картину. Для IC50 и CC50 модели на деревьях дают F1 выше 0.70. Для SI > median F1 около 0.67. Для SI > 8 F1 около 0.58, что ниже, но всё равно выше baseline. В практическом смысле это означает, что отбор соединений по порогам может быть более надёжной постановкой, чем попытка точно предсказать численный SI.

8. Выводы и рекомендации

Основной вывод: для IC50 и CC50 лучше всего работают ансамбли деревьев. Они устойчивы к мультиколлинеарности и лучше захватывают нелинейные связи между дескрипторами.

Для SI прямой регрессионный прогноз остаётся слабым местом. Здесь лучше использовать либо log1p-постановку, либо переходить к классификационным задачам по порогу. Если задача прикладная, наиболее разумный путь: отдельно оценивать IC50 и CC50, затем использовать SI как дополнительный расчётный критерий, а не как единственный прогнозируемый таргет.

Дальнейшие улучшения стоит делать не через случайное добавление моделей, а через химически осмысленные признаки: Morgan fingerprints, структурные фингерпринты, нормировки на размер молекулы и группировку соединений по близким химическим классам. Также желательно расширить выборку: сейчас около 1000 объектов, что ограничивает устойчивость моделей и делает экстремальные значения слишком влиятельными.

9. Состав материалов для сдачи

Для сдачи работа должна быть размещена в GitHub-репозитории. Рекомендуемая структура: отдельный EDA-ноутбук, отдельные ноутбуки для каждой регрессионной и классификационной задачи, файл с отчётом и исходный датасет.

Таблица 11. Рекомендуемая структура репозитория

Файл	Содержание
EDA.ipynb	первичный анализ и очистка данных
regression_ic50.ipynb	регрессия IC50
regression_cc50.ipynb	регрессия CC50
regression_si.ipynb	регрессия SI
classification_ic50.ipynb	классификация IC50 > median
classification_cc50.ipynb	классификация CC50 > median
classification_si.ipynb	классификация SI > median
classification_si8.ipynb	классификация SI > 8
coursework_whitepaper_report.docx	аналитический отчёт